

FATEC RIO CLARO
CURSO SUPERIOR DE TECNOLOGIA EM
INTELIGÊNCIA ARTIFICIAL

PROJETO DE MINERAÇÃO DE DADOS:
ANÁLISE DE REMUNERAÇÃO E HORAS EXTRAS
DO SENADO FEDERAL (2025)

Brendol Alves
Gabriel Nascimento
Luiz Henrique

Rio Claro - SP
2026

SUMÁRIO

1. Resumo
2. Introdução
3. Metodologia
 - 3.1 Base de Dados
 - 3.2 Pré-processamento
4. Algoritmos e Implementação
 - 4.1 concatenar.py
 - 4.2 limpeza_formatacao.py
 - 4.3 mineracao.ipynb
5. Resultados e Discussão
6. Conclusão
7. Agradecimentos
8. Referências Bibliográficas

1. RESUMO

O presente trabalho aplica técnicas de Mineração de Dados sobre informações públicas do Senado Federal Brasileiro referentes ao ano de 2025, com foco na análise de remuneração, gratificações e pagamento de horas extras aos servidores parlamentares. O estudo foi motivado por discussões públicas relacionadas ao crescimento de gastos com horas extras no setor público, incluindo reportagens investigativas publicadas pelo portal Metrópoles sobre pagamentos milionários associados à prática de horas extras em instituições governamentais.

A base de dados utilizada foi obtida diretamente do Portal da Transparência do Senado Federal, sendo composta por arquivos mensais em formato CSV contendo informações sobre remuneração básica, vantagens pessoais, função comissionada, gratificações natalinas, horas extras e demais auxílios financeiros.

O projeto utilizou um pipeline de tratamento e preparação dos dados desenvolvido em Python, além da aplicação de técnicas de análise exploratória e mineração de dados em ambiente Jupyter Notebook. Foram empregadas técnicas de clusterização utilizando o algoritmo K-Means e regras de associação por meio do algoritmo Apriori, buscando identificar padrões entre cargos, lotações e o recebimento de horas extras.

Os resultados indicaram padrões relevantes relacionados à concentração de pagamentos adicionais em determinados grupos funcionais e lotações específicas. Além disso, observou-se a possibilidade de utilização das técnicas de mineração de dados como ferramenta de apoio à transparência pública, auditoria governamental e fiscalização de gastos públicos.

O desenvolvimento deste projeto demonstra como técnicas de ciência de dados podem ser aplicadas sobre dados públicos para geração de conhecimento útil à sociedade e à administração pública.

2. INTRODUÇÃO

A crescente disponibilidade de dados públicos governamentais abriu espaço para aplicações avançadas de Ciência de Dados e Mineração de Dados no contexto da administração pública. A utilização dessas técnicas permite identificar padrões ocultos, anomalias e tendências relevantes em grandes volumes de informações administrativas e financeiras.

No Brasil, os portais de transparência disponibilizam informações detalhadas sobre gastos públicos, incluindo remuneração de servidores, benefícios e pagamentos extraordinários. Entretanto, a simples disponibilização dos dados não garante compreensão eficiente pela população, tornando necessária a aplicação de métodos analíticos capazes de transformar dados brutos em conhecimento interpretável.

Neste contexto, o presente trabalho propõe a análise da base de remuneração dos servidores parlamentares do Senado Federal Brasileiro no ano de 2025. O estudo foi motivado também por reportagens investigativas relacionadas ao pagamento de horas extras no setor público, como a matéria publicada pelo portal Metrôpoles intitulada “Farra da hora extra na Câmara: grupo de 13 vips recebeu R\$ 93 milhões”.

O objetivo central do projeto é aplicar técnicas de mineração de dados para identificar padrões remuneratórios, agrupamentos entre departamentos e possíveis associações relacionadas ao recebimento de horas extras, contribuindo para análises de transparência pública e apoio à fiscalização de gastos governamentais.

3. METODOLOGIA

3.1 Base de Dados

A base de dados utilizada neste projeto foi extraída diretamente do Portal da Transparência do Senado Federal Brasileiro. Os dados estão organizados em arquivos mensais no formato CSV referentes ao exercício de 2025.



No site do Transparência do Senado Federal Brasileiro, acessamos a aba “Consulta a Remuneração de Servidores”



Buscamos os arquivos em .csv

Consulta Remuneração

Dados de remunerações de cada mês em formato CSV:

2012 ▾

2013 ▾

2014 ▾

2015 ▾

2016 ▾

2017 ▾

2018 ▾

2019 ▾

2020 ▾

2021 ▾

2022 ▾

2023 ▾

2024 ▾

2025 ▾

2026 ▾

Aqui escolhemos os meses separados em anos (existe um script no repositório onde podemos fazer o download de todos os arquivos)

A estrutura da base contém informações relacionadas à remuneração dos servidores parlamentares, incluindo atributos financeiros e administrativos. Entre os principais campos analisados destacam-se:

- Remuneração Básica;
- Horas Extras;
- Gratificações;
- Vantagens Pessoais;
- Lotação de Exercício;
- Cargo;
- Função Comissionada;
- Auxílios e Benefícios.



Os dados não estão tratados pois: está codificado em latin-1 o que não permite as formações corretas, com informações ausentes (como a coluna SIMBOLO_FUNÇÃO) e as numerais na formatação brasileira (centavos como vírgula invés de ponto).

Ao todo, foram utilizados 12 arquivos CSV correspondentes aos meses de janeiro a dezembro de 2025.

3.2 Pré-processamento

O pré-processamento dos dados foi realizado utilizando scripts desenvolvidos em Python. Inicialmente, todos os arquivos CSV mensais foram concatenados em uma única base

94740	PARLAMENTAR;PARLAMENTAR;;;2024;Gabinete da Senadora Ana Paula Lobato;Normal;46366
94741	PARLAMENTAR;PARLAMENTAR;;;2024;Gabinete da Senadora Ana Paula Lobato;Suplementar;6
94742	PARLAMENTAR;PARLAMENTAR;;;2023;Gabinete do Senador Fernando Farias;Normal;46366
94743	PARLAMENTAR;PARLAMENTAR;;;2023;Gabinete do Senador Fernando Farias;Suplementar;6
94744	PARLAMENTAR;PARLAMENTAR;;;2025;Gabinete do Senador Jos Lacerda;Normal;46366
94745	PARLAMENTAR;PARLAMENTAR;;;2025;Gabinete do Senador Jos Lacerda;Suplementar;6
94746	PARLAMENTAR;PARLAMENTAR;;;2025;Gabinete do Senador Bruno Bonetti;Normal;23930
94747	PARLAMENTAR;PARLAMENTAR;;;2025;Gabinete do Senador Bruno Bonetti;Suplementar;6
94748	

- Conversão de colunas financeiras para formato numérico;
- Tratamento de valores nulos;
- Padronização textual;
- Remoção de espaços e inconsistências;
- Criação de variáveis derivadas;
- Codificação ordinal para funções comissionadas.

COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2023;	AUDITORIA DO SENADO FEDERAL;	Normal;	3568,67;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2023;	AUDITORIA DO SENADO FEDERAL;	Suplementar;	0,0;	0,0;	0,0;	0,0;	0,0;	1189,56;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2019;	GABINETE DO SENADOR VENEZIANO VITAL DO RÊGO;	Normal;	3568,67;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2019;	GABINETE DO SENADOR VENEZIANO VITAL DO RÊGO;	Suplementar;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2023;	BLOCO PARLAMENTAR DEMOCRACIA;	Normal;	3568,67;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2023;	BLOCO PARLAMENTAR DEMOCRACIA;	Suplementar;	0,0;	0,0;	0,0;	0,0;	0,0;	1189,56;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2013;	SERVIÇO DE APOIO ÀS CONTRATATAÇÕES DE TI;	Normal;	3568,67;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2013;	SERVIÇO DE APOIO ÀS CONTRATATAÇÕES DE TI;	Suplementar;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2020;	GABINETE DA DGER;	Normal;	3568,67;	0,0;	0,0;	0,0;	0,0;	182,66;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2020;	GABINETE DA DGER;	Suplementar;	0,0;	0,0;	0,0;	0,0;	0,0;	1189,56;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2011;	GABINETE DO QUARTO SUPLENTE DE SECRETÁRIO;	Normal;	2581,89;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;
COMISSÃO:	CARGO	EM	COMISSÃO:	AJUDANTE	PARLAMENTAR	INTERMEDIÁRIO:	AP-02;SEM	FUNÇÃO:	2011;	GABINETE DO QUARTO SUPLENTE DE SECRETÁRIO;	Suplementar;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;	0,0;

Após o tratamento, a base final foi exportada para utilização no ambiente de mineração de dados e análise exploratória.

4.1 Script concatenar.py

O arquivo `concatenar.py` é responsável pela consolidação dos arquivos mensais da base de dados. O script realiza a leitura automática dos arquivos CSV presentes na pasta correspondente ao ano de 2025.

O arquivo `concatenar.py` é responsável pela consolidação dos arquivos mensais da base de dados. O script realiza a leitura automática dos arquivos CSV presentes na pasta correspondente ao ano de 2025.

```

1 import pandas as pd
2 import glob
3 import os
4
5 # 1. Definir o padrão do nome dos arquivos (relativo ao próprio script)
6 script_dir = os.path.dirname(__file__)
7 caminho_dos_arquivos = os.path.join(script_dir, '2025/SF_ConsultaRemuneracaoServidoresParlamentares_2025*.csv')
8 arquivos_encontrados = glob.glob(caminho_dos_arquivos)
9
10 # Ordenar os arquivos para garantir que a sequência mensal esteja correta
11 arquivos_encontrados.sort()
12
13 lista_dataframes = []
14
15 for arquivo in arquivos_encontrados:
16     # 2. Ler o arquivo
17     # Skiprows=1 ignora a linha "ÚLTIMA ATUALIZAÇÃO" que está no topo dos seus arquivos
18     df_mes = pd.read_csv(arquivo, sep=';', encoding='latin-1', skiprows=1)
19
20     # 3. Extrair o número do mês do nome do arquivo para manter o histórico
21     # Exemplo: do nome '...202501.csv' ele extrai '01'
22     nome_base = os.path.basename(arquivo)
23     mes_str = nome_base.split('_')[-1].replace('.csv', '')[-2:]
24     df_mes['MES_REFERENCIA'] = int(mes_str)
25
26     lista_dataframes.append(df_mes)
27
28 # 4. Concatenar todos os DataFrames da lista num único objeto
29 if not lista_dataframes:
30     raise SystemExit("Nenhum arquivo encontrado para concatenar. Verifique o diretório '2025' e o padrão dos arquivos.")
31
32 df_final = pd.concat(lista_dataframes, ignore_index=True)
33
34 # Salvar no mesmo diretório do script
35 output_path = os.path.join(script_dir, '2025/concatenado_2025.csv')
36 df_final.to_csv(output_path, index=False, sep=';', encoding='latin-1')
37 print(f"Arquivo salvo em: {output_path}")
38
39 # Verificar o resultado
40 print(f"Total de linhas após concatenação: {len(df_final)}")
41 print(df_final.head())
42
43

```

Código concatenar.py

As principais funcionalidades implementadas incluem:

- Leitura automática dos arquivos utilizando a biblioteca Pandas;
- Extração do mês de referência a partir do nome do arquivo;
- Inclusão da coluna MES_REFERENCIA;
- Concatenação de todos os DataFrames;
- Exportação da base consolidada (base_senado_mineracao.csv).

Este processo automatiza a unificação dos dados mensais, reduzindo inconsistências e facilitando etapas posteriores de análise.

4.2 Script limpeza_formatacao.py

O arquivo limpeza_formatacao.py realiza o tratamento e padronização da base consolidada.

```
# Preenche valores vazios (NaN) das colunas financeiras com 0
df[colunas_dinheiro] = df[colunas_dinheiro].fillna(0)

# ETAPA 2: TRATAMENTO DA COLUNA SÍMBOLO FUNÇÃO
if 'SÍMBOLO FUNÇÃO' in df.columns:
    # 2.1 Preenche os valores nulos com a categoria padrão "SEM FUNÇÃO"
    df['SÍMBOLO FUNÇÃO'] = df['SÍMBOLO FUNÇÃO'].fillna('SEM FUNÇÃO')

    # 2.2 Limpa espaços em branco ocultos e padroniza tudo em maiúsculo
    df['SÍMBOLO FUNÇÃO'] = df['SÍMBOLO FUNÇÃO'].astype(str).str.strip().str.upper()

    # 2.3 Criação da hierarquia numérica (Ordinal Encoding)
    # Nota: Mapeamos do menor (sem função = 0) para os maiores níveis de gratificação (ex: FC-1 a FC-5)
    mapeamento_funcao = {
        'SEM FUNÇÃO': 0,
        'FC-1': 1,
        'FC-2': 2,
        'FC-3': 3,
        'FC-4': 4,
        'FC-5': 5
    }

    # Aplica o mapeamento. Caso apareça alguma sigla inesperada no CSV, o fillna(0) garante que não quebre
    df['FUNCAO_NUMERICA'] = df['SÍMBOLO FUNÇÃO'].map(mapeamento_funcao).fillna(0).astype(int)

# ETAPA 3: PADRONIZAÇÃO DE OUTROS TEXTOS E NULOS
if 'LOTAÇÃO EXERCÍCIO' in df.columns:
    df['LOTAÇÃO EXERCÍCIO'] = df['LOTAÇÃO EXERCÍCIO'].astype(str).str.strip().str.upper()

if 'CARGO' in df.columns:
    df['CARGO'] = df['CARGO'].fillna('NÃO APLICÁVEL').astype(str).str.strip().str.upper()

if 'REFERÊNCIA CARGO' in df.columns:
    df['REFERÊNCIA CARGO'] = df['REFERÊNCIA CARGO'].fillna('SEM REF').astype(str).str.strip().str.upper()

# ETAPA 4: EXPORTAÇÃO DO ARQUIVO FINAL CLEAN
arquivo_saida = os.path.join(script_dir, '2025/base_senado_mineracao.csv')
df.to_csv(arquivo_saida, sep=';', index=False, encoding='utf-8')

print(f"\n[SUCESSO] O arquivo limpo foi salvo como: '{arquivo_saida}'")
print("\n--- Amostra do tratamento da coluna Símbolo Função ---")
print(df[['SÍMBOLO FUNÇÃO', 'FUNCAO_NUMERICA']].drop_duplicates().reset_index(drop=True))
```

Código limpeza_formatacao.py

As principais etapas executadas são:

- Conversão de valores monetários;
- Transformação de separadores decimais brasileiros;
- Tratamento de valores ausentes;
- Padronização textual;
- Normalização de categorias;
- Criação da variável ordinal FUNCAO_NUMERICA.

O script também realiza a exportação da base final tratada em formato CSV para posterior utilização no notebook de mineração.

4.3 Notebook mineracao.ipynb

O notebook mineracao.ipynb concentra as etapas de análise exploratória e aplicação dos algoritmos de mineração de dados.

As análises desenvolvidas incluem:

- **Estatísticas descritivas;** Com o Pandas através do método `.describe()` aplicado às colunas numéricas (como `REMUN_BASICA`, `REM_LIQUIDA`, `HORAS_EXTRAS`, etc.). Desta forma as estatísticas descritivas foram utilizadas para identificar a média, mediana, desvio padrão, valores mínimos e máximos das remunerações. Elas revelam a assimetria dos dados (por exemplo, a diferença entre a remuneração básica e a líquida após os descontos de `IMPOSTO_RENDA` e `PREVIDÊNCIA`) e ajudam a detectar outliers (valores discrepantes) antes de aplicar os modelos preditivos.

```
# Carregar o novo arquivo CSV
caminho_arquivo = '2025/base_senado_mineracao.csv'
df_bruto = pd.read_csv(caminho_arquivo, delimiter=';')

# Filtrar apenas o ano de exercício de 2025
df_2025 = df_bruto[df_bruto['ANO_EXERCÍCIO'] == 2025].copy()

print(f"Total de registros em 2025: {df_2025.shape[0]}")
df_2025[['LOTAÇÃO_EXERCÍCIO', 'HORAS_EXTRAS', 'REM_LIQUIDA', 'MES_REFERENCIA']].head()
```

Total de registros em 2025: 8937

	LOTAÇÃO_EXERCÍCIO	HORAS_EXTRAS	REM_LIQUIDA	MES_REFERENCIA
363	GABINETE DA SENADORA IVETE DA SILVEIRA	0.0	1725.48	1
466	GABINETE DO SENADOR MAGNO MALTA	0.0	2745.10	1
471	GABINETE DO SENADOR MAGNO MALTA	0.0	2198.45	1
472	GABINETE DA LIDERANÇA DA BANCADA FEMININA	0.0	2293.04	1
473	GABINETE DA LIDERANÇA DO PODEMOS	0.0	1725.48	1

Trecho do código mineracao.ipynb

- **Distribuição salarial;** Os salários não seguem uma distribuição perfeitamente normal; eles costumam ser altamente assimétricos à direita (poucas pessoas ganhando salários muito altos e a maioria concentrada nas faixas iniciais/intermediárias). A análise foca em comparar a folha Normal com a Suplementar (onde entram gratificações natalinas ou acertos) e como variáveis como o teto constitucional (`REVERSAO_TETO_CONST`) impactam o salário final líquido (`REM_LIQUIDA`).




Gráfico dos Funcionários com Hora Extra X Sem Hora Extra, mês a mês

• **Análise de horas extras;** Foi feita uma análise agregada por LOTAÇÃO EXERCÍCIO (Gabinete ou Departamento) para identificar quais setores apresentam maior recorrência e volume financeiro de horas-extras. Essa variável foi identificada como um dos principais fatores de volatilidade na folha, sendo posteriormente utilizada como um atributo (feature) essencial para os modelos de clusterização e classificação de risco de estouro de orçamento.

```
# Tratamento de valores nulos no desvio padrão (Volatilidade)
df_departamentos['Volatilidade_HE'] = df_departamentos['Volatilidade_HE'].fillna(0)

# Cálculo do impacto percentual das Horas Extras na folha do departamento
df_departamentos['Percentual_HE_Na_Folha'] = (df_departamentos['Gasto_Medio_HE'] / df_departamentos['Gasto_Total_Folha']) * 100
df_departamentos['Percentual_HE_Na_Folha'] = df_departamentos['Percentual_HE_Na_Folha'].fillna(0)

# Filtrar apenas departamentos que registraram gastos com HE em 2025
df_analise = df_departamentos[df_departamentos['Gasto_Medio_HE'] > 0].reset_index(drop=True)

print(f"Total de departamentos com Horas Extras em 2025: {df_analise.shape[0]}")
df_analise.head()
```





✓ 0.2s

Total de departamentos com Horas Extras em 2025: 38

	LOTAÇÃO EXERCÍCIO	Gasto_Medio_HE	Volatilidade_HE	Gasto_Total_Folha	Percentual_HE_Na_Folha
0	BLOCO PARLAM. DEMOCRACIA (MDB/UNIÃO/PODEMOS/PSDB)	476.470000	433.039939	32094.713750	1.484575
1	BLOCO PARLAMENTAR VANGUARDA (PL/NOVO)	1726.918333	1355.833465	8579.193333	20.129146
2	COORDENAÇÃO DE EVENTOS	35.985000	88.144888	2989.206667	1.203831
3	DIRETORIA-EXECUTIVA DE GOV. CONTRAT. E LICITAT...	119.278889	357.836667	54495.978889	0.218876
4	GABINETE DA DGER	1070.375714	1428.635409	56298.100000	1.901264

Trecho do código mineracao.ipynb exibindo a quantidade de departamento (LOTAÇÃO_EXERCÍCIO) com horas extras

• **Visualizações gráficas;** O código utiliza as bibliotecas matplotlib.pyplot e seaborn (com o estilo whitegrid) para transformar números brutos em insights visuais.



Exemplos dos gráficos utilizados no projeto

Foram gerados gráficos de distribuição (como histogramas ou boxplots) para avaliar a dispersão salarial, além de gráficos de barras horizontais para o ranking de setores. O objetivo visual é duplo: testar as premissas estatísticas visualmente (verificação de outliers e assimetria) e comunicar de forma clara para o usuário final quais gabinetes ou departamentos demandam maior atenção fiscal.

• **Clusterização utilizando K-Means;** Durante a análise de otimização do algoritmo K-means, o cálculo do Coeficiente de Silhueta indicou que o ponto máximo de separação estatística ocorreria com um número elevado de agrupamentos ($k = 37$). Contudo, do ponto de vista prático e de gestão de dados, um modelo com 37 clusters reduz drasticamente a interpretabilidade humana e a utilidade macro das informações para auditoria. Portanto, sacrificou-se uma fração marginal de performance matemática em prol da aplicabilidade do modelo, optando-se estrategicamente por $k = 5$. Esse número permite uma segmentação clara, acionável e visualmente compreensível dos perfis de gastos e risco do Senado.




Gráfico do cálculo da Silhueta




Gráfico K-means: Segmentação de Departamentos do Senado (Horas Extras - 2025)

• **A curva ROC:** A Curva ROC mede a capacidade de um modelo classificador em distinguir duas classes (por exemplo: um setor que vai estourar o orçamento versus um setor que ficará dentro do limite). O AUC (Área Sob a Curva) varia de 0,5 (classificação aleatória) a 1,0 (modelo perfeito). Um AUC de 0,89 é um resultado excelente. Significa que o modelo possui um poder de discriminação de 89%, sendo altamente eficiente e confiável para prever anomalias ou riscos orçamentários antes que eles ocorram.





Gráfico Avaliação do Modelo Preditivo - FATEC RC

• **Regras de associação utilizando Apriori:** O algoritmo Apriori é utilizado para encontrar regras de associação (padrões do tipo "Se acontece A, então acontece B"). No caso do Senado, ele serve para descobrir, por exemplo, se uma determinada categoria de cargo ou tipo de folha (Suplementar) está frequentemente associada a um volume alto de HORAS_EXTRAS. Suas métricas de validação são o Suporte e a Confiança.



```
=====
TABELA DE APURAÇÃO PREDITIVA DE RISCO ORÇAMENTÁRIO
=====
      LOTAÇÃO EXERCÍCIO  PROB_ESTOURO_%  Gasto_Medio_HE  QTD_SERVIDORES
0      GABINETE DA SENADORA TEREZA CRISTINA      100.00%      R$ 4,147.24      20
1      GABINETE DO SENADOR JAIME BAGATTOLI      99.00%      R$ 4,201.56      13
2      GABINETE DO SENADOR LAÉRCIO OLIVEIRA      98.00%      R$ 4,054.78      28
3      GABINETE DO SENADOR ALAN RICK      98.00%      R$ 4,637.57      21
4      GABINETE DO SENADOR VENEZIANO VITAL DO RÊGO      89.00%      R$ 3,103.37      65
5      GABINETE DA SENADORA ANA PAULA LOBATO      87.00%      R$ 2,832.69      13
6      GABINETE DO SENADOR LUCAS BARRETO      82.00%      R$ 3,636.78      37
7      GABINETE DO SENADOR SÉRGIO PETECÃO      78.00%      R$ 3,180.43      24
```

A utilização do ambiente Jupyter Notebook possibilitou maior flexibilidade analítica, permitindo exploração iterativa dos dados e interpretação visual dos resultados.

5. RESULTADOS E DISCUSSÃO

Os resultados obtidos demonstraram a existência de padrões relevantes relacionados ao pagamento de remunerações adicionais e horas extras dentro da estrutura administrativa analisada. A aplicação do algoritmo K-Means permitiu identificar agrupamentos de lotações e cargos com características semelhantes de remuneração. Alguns grupos apresentaram concentração elevada de pagamentos extraordinários, indicando possíveis padrões administrativos específicos. As regras de associação geradas pelo algoritmo Apriori revelaram relações frequentes entre determinados cargos, lotações e o recebimento recorrente de horas extras. Essas associações demonstram como técnicas de mineração de dados podem auxiliar processos de auditoria e transparência pública. A análise exploratória também permitiu identificar diferenças salariais significativas entre categorias funcionais, além de evidenciar a distribuição desigual de benefícios e gratificações. Embora o projeto tenha finalidade acadêmica, os resultados mostram potencial aplicação prática em órgãos de controle, fiscalização e governança pública.

6. CONCLUSÃO

O presente projeto demonstrou a viabilidade da aplicação de técnicas de mineração de dados em bases públicas governamentais relacionadas à remuneração de servidores. A utilização de algoritmos de agrupamento e regras de associação possibilitou identificar padrões complexos que dificilmente seriam observados apenas por métodos tradicionais de análise estatística.

Como melhorias futuras, o projeto pode incorporar:

- Técnicas avançadas de aprendizado de máquina;
- Detecção automática de anomalias;
- Dashboards interativos;
- Integração com bancos de dados em tempo real;
- Modelos preditivos para gastos públicos.

Além disso, futuras versões podem utilizar processamento distribuído para lidar com bases ainda maiores, além de integrar dados de outros órgãos públicos federais. A aplicabilidade do projeto é ampla, podendo auxiliar auditorias públicas, iniciativas de transparência governamental, controle social e estudos acadêmicos relacionados à administração pública e ciência de dados.

7. AGRADECIMENTOS

Agradecemos à Professora Dra. Angela Rosa Locateli de Godoy pela orientação acadêmica e incentivo ao desenvolvimento do projeto e também à FATEC Rio Claro pelo suporte institucional e estrutura disponibilizada ao longo do curso de Tecnologia em Inteligência Artificial. Estendemos os agradecimentos ao Senado Federal Brasileiro pela disponibilização pública dos dados utilizados neste trabalho por meio do Portal da Transparência. Por fim, agradecemos ao portal Metrôpoles pelas reportagens investigativas que contribuíram para contextualização e motivação temática deste estudo.

8. REFERÊNCIAS BIBLIOGRÁFICAS

BRASIL. Senado Federal. Portal da Transparência. Disponível em:

<https://www12.senado.leg.br/dados-abertos/conjuntos?portal=Administrativo&grupo=gestao-de-pessoas>

METRÓPOLES. Farra da hora extra na Câmara: grupo de 13 vips recebeu R\$ 93 milhões. Disponível em: <https://www.metropoles.com/colunas/andreza-matais/farra-da-hora-extra-na-camara-grupo-de-13-vips-recebeu-r-93-milhoes>

PANDAS DEVELOPMENT TEAM. Pandas Documentation. Disponível em:

<https://pandas.pydata.org/>.

SCIKIT-LEARN. Machine Learning in Python. Disponível em: <https://scikit-learn.org/>.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. Data Mining: Concepts and Techniques. Morgan Kaufmann, 2011.

WITTEN, Ian H.; FRANK, Eibe; HALL, Mark A. Data Mining: Practical Machine Learning Tools and Techniques. Morgan Kaufmann, 2016.

Repositório do projeto: <https://github.com/brendolalves/Projeto-de-Mineracao-de-Dados>